

Čtení č. 1 – Hledání intervalů a metody dělení prostoru

student: **Peter Ďurica**, xduric05

Příprava na čtení

Uveďte alespoň 3 dotazy k danému tématu čtení a případným nejasnostem. Pokud je vše jasné, uveďte věci, které sami pokládáte za nejdůležitější pro pochopení problematiky a ostatní by je určitě měli vědět.

- Konštrukcia Skip Trees nebola podľa mňa dostatočne dobre vysvetlená. Aspoň teda ja, ktorý sa so Skip Trees nestretol, som to len z prvého dokumentu úplne nepochopil a musel som si dohľadať dodatočné informácie.
- Úplne som nepochopil Query v Ranged Trees, rád by som videl vizualizáciu pre lepšie pochopenie.
- V druhom dokumente nechápem ako môžu zaistiť určitú presnosť v algoritme hľadania najbližšieho suseda (NN algoritmus). V sekcii 2 sa píše o hodnotení presnosti výsledku ako o funkcii kde sa používa ϵ ako rozdiel vzdialenosti od nájdeného NN a naozajstného NN. Potom v sekcii 3 píšú že pri tréningu zistia aký počet listov musia prehľadať, aby dosiahli dostatočnú presnosť. Nechápem úplne ako si môžu byť istý že ich nájdený NN je určite aspoň vo zvolenej vzdialenosti od reálneho NN.
- V druhom dokumente v tabuľke 1 nechápem Memory Used stĺpec a neviem pomerom akých čísel je vypočítaný. Predpokladám že na uloženie celého datasetu do akceleračných štruktúr je vždy potrebná pamäť, ktorá je aspoň tak veľká ako celý dataset ale v stĺpci sú len čísla menšie ako 1.

Poznámky ze čtení

Zformulujte své poznatky ze čtení. K čemu jsou tyto metody dobré? Kdy je která metoda vhodná? Co mi v článku připadá silné a co slabé? Co stále ještě nechápu? Alespoň 5 bodů.

- Skip Tree je vhodnejšia dátová štruktúra oproti binárnym stromom, keďže má rovnakú zložitosť ale jednoduchšie pridávanie a odoberanie hodnôt.
- Jednoduchá implementácia kd-stromu môže byť účinná na ukladanie nízko-dimenziálnych dát ale pri desiatkach dimenzií stráca svoju efektivitu a je potrebné použiť zložitejšie implementácie
- Range stromy sa skladajú z hlavného binárneho stromu napríklad podľa dimenzie X, ktorý má následne na každom svojom uzle zostavený asociačný binárny strom z rovnakých hodnôt ako v hlavnom strome ale rozdelený podľa dimenzie Y. Toto sa môže zdať že asociačné stromy na každom uzle budú zaberať príliš veľa pamäte, ale to nieje pravda, keďže počet hodnôt v týchto stromoch sa rýchlo začne znižovať a hrubá väčšina asociačných stromov má len zlomok hodnôt hlavného stromu.
- Autori knižnice FLANN zistili že k-means stromy a les náhodných kd-stromov sú najvhodnejšie dátové štruktúry na hľadanie približného suseda. Knižnica FLANN umožňuje vložiť ľubovoľné dátové hodnoty, nastaviť si váhy na dôležitosť času stavania dátovej štruktúry a pamäte ktorú tieto stromy zaberú. Na základe toho vyberú najvhodnejšiu dátovú štruktúru pre dané dáta.
- Rýchlosť hľadania najbližšieho suseda pri zachovaní presnosti sa zo zvýšením dimenzií výrazne znižuje pri náhodných vektoroch. Avšak v skutočnom živote existuje medzi bodmi zvyčajne určitá korelácia a preto zvyšovanie dimenzií nemá taký dopad na rýchlosť ako pri náhodných vektoroch.

Kontrolní otázky

Stručně odpovězte na kontrolní otázky uvedené na Wiki stránce.

1. Co je to problém hledání intervalů (Range Searching) a jaké má praktické využití?

Problém hľadania intervalu spočíva v nájdení všetkých bodov v danom dátovom priestore, ktoré spadajú do určitého rozsahu. Prakticky sa využíva pri filtrovaní dát v databázových systémoch alebo pri lokalizácii bodov v súradnicovom systéme.

2. Jaké výhody má datová struktura Skip Tree a jak se do ní vkládá nová hodnota/uzel?

Problém binárního stromu je složitost přidávání a odoberania hodnôt do už postaveného stromu. Toto rieši Skip Tree, ktorý je na rozdiel od bin. tree randomizovaná dátová štruktúra a má jednoduchú implementáciu vkladania a odstránenia uzlov. Uzol sa najprv vloží na svoju pozíciu v zoradenom linked listu v spodnom riadku Skip Tree. Následne sa hádže mincou koľko kópií svojej hodnoty bude mať uzol v riadkoch Skip Tree nad sebou. Po pridaní týchto kópií je proces pridania nového uzlu hotový. Tento proces je jednoduchší ako riešiť vyrovnanosť binárneho stromu a prechod Skip Tree pri hľadaní uzlu sa podobá práve prechodom binárnym stromom.

3. Jak probíhá tvorba kd-tree?

V najjednoduchšej implementácii sa na každej úrovni stromu strieda dimenzia dát, podľa ktorej budú dáta rozdelené na dve polovice. Napríklad pri jednoduchom 2D kd-strome to prebieha takto:

1. Dáta sa zoradia podľa hodnoty v dimenzii X.
2. Zvolí sa medián zo zoradených hodnôt
3. Dáta sú vložené buď na ľavú alebo pravú vetvu podľa veľkosti ich hodnoty v dimenzii X oproti mediánu. Následne sa každá vetva už triedi samostatne.
4. V druhom kroku sa zvolí medián všetkých hodnôt vo vetve na dimenzii Y a dáta sú znova podľa neho zoradené do ďalších 2 vetiev
5. Proces sa znova opakuje ale znova sa medián vyberá na dimenzii X pokiaľ nebude vo vetve len 1 hodnota.

V zložitejších implementáciách nemusí byť delená dimenzia volená striedavo alebo náhodne, ale podľa najväčšieho dopadu na dáta vo vetve.

4. Jak lze definovat tzv. Approximate Nearest Neighbors Search?

ANN je algoritmus na rýchle vyhľadanie približne najbližších susedov v dátovom priestore, pričom obetuje presnosť nájdeného suseda (nemusí byť vždy najbližší) za vyššiu rýchlosť oproti exaktným metódam.

5. Jaké dvě základní datové struktury pro ANN search používá knihovna FLANN?

FLANN využíva k-means stromy s nastaviteľným počtom vetvenia a počtom iterácií. Druhou dátovou štruktúrou je les náhodných kd-stromov u ktorých sa vyberá dimenzia na delenie náhodne zo zoznamu piatich dimenzií s najväčším dopadom na delenie.

Doporučení pro budoucí čtení

Co vám vyhovovalo a co nevyhovovalo na čtení? Přineslo vám čtení něco pozitivního? Které prvky by měly být zachovány, zesíleny, potlačeny, eliminovány? Alespoň jeden bod.

Možno by bolo lepšie priamo počas čítania článkov zamerať na pár zaujímavých otázok študentov a priamo ich zodpovedať počas toho ako sa danej štruktúre venujeme. Ale inak bola takáto forma prednášky celkom príjemná zmena a cítim že mám lepšie pochopenie látky práve vďaka forme tejto prednášky.