



UPA projekt - 3. část

Príprava dát a ich popisná charakteristika

23. januára 2025

Bc. Tomáš Ondrušek(xondru18)

Bc. Peter Ďurica(xduric05)

Obsah

1	Exploratívna analýza	1
1.1	Analýza atribútov	1
1.2	Rozloženie hodnôt atribútov	1
1.3	Hľadanie odľahlých hodnôt	5
1.4	Analýza chýbajúcich hodnôt	5
1.5	Korelačná analýza	5
2	Prvá varianta dátovej sady – Diskretizácia numerických atribútov	7
2.1	Kopírovanie dát:	8
2.2	Diskretizácia numerických atribútov:	8
2.3	Uloženie spracovaných dát:	9
3	Druhá varianta dátovej sady – Normalizácia numerických atribútov a transformácia kategorických atribútov na numerické	10
3.1	Kopírovanie dát:	10
3.2	Normalizácia numerických atribútov:	10
3.3	Transformácia kategorických atribútov na numerické:	10
3.4	Uloženie spracovaných dát:	11

1 Exploratívna analýza

Ako dataset pre tento projekt sme sa rozhodli použiť nami vydolované dáta z prvej časti projektu. Dáta pochádzajú z hokejového internetového obchodu [Top On Ice](#). Dataset obsahuje informácie o hokejkách, ktoré boli v čase dolovania v predaji.

1.1 Analýza atribútov

Náš dataset má celkovo 12 atribútov. Z analýzy sme sa rozhodli vynechať atribúty **URL** a **Name** pretože obsahujú len odkaz do obchodu a názov hokejky. Teda obsahujú len výlučne jedinečné hodnoty pre každú konkrétnu hokejku a nie sú vhodné pre analýzu. Zo zvyšných 10 atribútov sú 3 numerické a 7 kategorických. Z kategorických atribútov nie je ani jeden ordinárny aj keď sme dlho zvažovali nad atribútom **Age Group**. Nakoniec sme sa z dôvodu, ktorý priblížim v analýze rozloženia hodnôt rozhodli, že nebude ordinárny.

V prvej tabuľke sú informácie z analýzy atribútov pre numerické hodnoty. Stĺpce tabuľky znázorňujú počet jedinečných hodnôt v tabuľke, najčastejšie vyskytovanú hodnotu, Rozptyl najmenšej a najvyššej hodnoty, najmenšiu a najvyššiu hodnotu a nakoniec aritmetický priemer všetkých hodnôt a smerodajnú odchýlku pre danú množinu.

Názov	Jed. hodnoty	Modus	Rozptyl	Min	Max	Priemer	Štand. odchylka
Price	87	199,95	307,02	42,95	349,97	172,67	65,7
Flex	23	85	90	10	100	64,01	18,08
Stick Length	22	60	26	38	64	58,08	4,69

Tabuľka 1: Numerické atribúty

V druhej tabuľke sú informácie z analýzy atribútov pre kategorické hodnoty. Tabuľka je teda jednoduchšia ako pre numerické jednotky. Obsahuje počet jedinečných hodnôt každého atribútu ako aj 3 najčastejšie sa vyskytujúce hodnoty.


Názov	Jed. hodnoty	Naj. hodnota	2. Naj. hodnota	3. Naj. hodnota
Manufacturer	8	Warrior	Bauer	True
Age Group	4	Senior	Intermediate	Junior
Hand	2	right	left	Unknown
Blade Curve	36	W03	W28	P28
Brand	8	Warrior	Bauer	True
Family	21	Covert	Alpha	Nexus
Composite Stick Brand	7	Warrior	Bauer	True

Tabuľka 2: Kategorické atribúty

1.2 Rozloženie hodnôt atribútov


Pre analýzu rozloženia hodnôt sme si pripravili päť grafov na vizualizáciu vplyvu dát medzi sebou. Každý graf je rozdielneho typu a preto sme sa snažili vybrať pre ne najlepšiu množinu hodnôt, ktorá by naplno využila všetky vlastnosti grafu, a zároveň aby sme využili čo najviac atribútov datasetu.

Prvý graf je jednoduchší a znázorňuje histogram atribútu **Hand**. Niektoré hodnoty v databáze neboli atomické a obsahovali aj hodnotu left aj right. Tieto hodnoty sme explodovali a zarátali ich samostatne. Vo výsledku je vidieť že na stránke je v predaji tesne viac hokejok napravo ako naľavo. Veľké množstvo dát však nemalo k dispozícii tento atribút a teda reálna hodnota môže byť rozdielna.




Obr. 1: Histogram zobrazujúci smer zahnutia hokejky

Pri druhom grafe sme sa rozhodli pre huslový graf flexu (úrovne tvrdosti) hokejky nad každou značkou. Huslový graf pozostáva z boxplotu (ktorý bližšie popíšem pri nasledujúcom grafe) a vizualizáciou rozloženia hustoty jednotlivých hodnôt. Šírka farebne zafarbenej časti korešponduje s frekvenciou výskytu rovnakých hodnôt. Z následného grafu môžeme vidieť, že najčastejšia hodnota flexu býva v rozmedzí 60 až 80 pri všetkých značkách. Zároveň skoro všetky značky ponúkajú možnosti od 10 do 100, ale už v menších číslach. Zaujímavý je ešte graf značky **Fischer** kde je vidno že sa zameriavajú na vysoké a nízke hodnoty flexu, ale v stredných hodnotách už nemajú toľko ponúk. Grafy značiek **Graf** a **Vanx** nenabúdajú podobnú podobu ako ostatné značky pravdepodobne kvôli nízkemu počtu hokejok a teda menšiemu rozloženiu hodnôt.




Obr. 2: Huslový graf flexu hokejky nad značkami

Ako tretí graf sme zvolili boxplot ceny hokejok nad značkami. Boxplot sa skladá z 5 vecí - maximum, minimum, box, medián a odľahlé hodnoty. Box je krabička v strede grafu, ktorá môže byť zafarbená. V nej je čiara, ktorá symbolizuje medián dátovej sady. Krabička je oddelená zhora aj zdola hodnotami $Q1$ a $Q3$, ktoré znázorňujú polohu hodnôt 25 percentilu a 75 percentilu, čiže hodnoty oddelujúce prvý a druhý kvartál a tretí a štvrtý kvartál. Minimá a maximá sú buď úplné minimá a maximá dátovej sady alebo hodnoty $Q1 - 1.5 \times IQR$ a $Q3 + 1.5 \times IQR$ ak sa maximá/minimá nachádzajú nad/pod týmito hodnotami. IQR je hodnota $Q3 - Q1$ a znázorňuje výšku krabičky. Odľahlé hodnoty sú hodnoty nad/pod maximom/minimom. Tento graf sa môže použiť teda priamo na identifikovanie odľahlých hodnôt dátovej sady. V našom grafe je vidno že väčšina značiek ponúka hokejky od 50 do 300 eur s mediánom medzi 150 až 200 eur. Takisto na našom grafe nie sú žiadne odľahlé hodnoty ak sú ceny rozdelené podľa značiek. Z grafu je rovnako vidieť, že **Bauer** ponúka hokejky aj vo vyššej cene a to za 350 euro, zatiaľ čo **Fischer** sa skôr zameriava na lacnejšie hokejky do 200 euro s mediánom okolo 100 euro. Na značkách **Graf** a **Vanx** sa nám nepodarilo vytvoriť boxploty kvôli tomu, že ich hokejky majú všetky rovnakú cenu.




Obr. 3: Boxplot ceny hokejok nad značkami

Štvrtý graf je kvantilný. Zobrazuje vývoj rastu hodnoty pri prechode dátovou sadou. Hodnoty sa zoradia od najmenej po najväčšiu a vypočíta sa im ich kvantilná poloha v sade. Následne sa tieto hodnoty podľa vypočítanej polohy vykreslia na grafe. Na našom grafe môžeme vidieť že zo začiatku hodnoty rýchlo vyrastú na hodnotu 50 a následne sa dlho držia na podobných hodnotách kým na konci znova rýchlo vyrastú na 100. Toto znázorňuje podobný trend ako v huslovom grafe kde sa ukázalo že najväčšia hustota rozloženia je medzi hodnotami 60 až 80. Čím rýchlejšie hodnoty na grafe rastú, tým je menej hodnôt v danom kvantile.



Obr. 4: Kvantilný graf flexu

Posledný graf zobrazuje dĺžky hokejok pre jednotlivé vekové kategórie. Dĺžka hokejok je meraná v palcoch. Z grafu je vidieť že hokejky *Intermediate* a *Senior* sú dlhšie ako hokejky *Junior* a *Youth*. Inak sú hodnoty medzi *Intermediate* a *Senior* viac menej podobné aj keď *Senior* má pár dlhších hokejok. Takisto aj *Junior* a *Youth* majú podobné hodnoty ale *Youth* má pár kratších hokejok. Aj kvôli tomuto grafu sme sa rozhodli, že atribút *Age Group* nebude ordinálny.



Obr. 5: Scatter graf dĺžky hokejky nad vekovými skupinami

1.3 Hľadanie odľahlých hodnôt

Pri hľadaní odľahlých hodnôt sme použili rovnaký algoritmus ako sa používa pri boxplote. Zistili sme hodnoty $Q1$ a $Q3$, čiže hodnoty na 25. a 75. percentile. Následne sme si vypočítali ich rozdiel pomocou rovnice $ICQ = Q3 - Q1$. Keď už vieme ICQ , vypočítame si spodnú a hornú hranicu hodnôt, pričom spodná hranica je $Q1 - 1.5 \times IQR$ a horná hranica je $Q3 + 1.5 \times IQR$. Hodnoty pod a nad týmito hranicami sú odľahlé hodnoty.

V našom datasete sú len 3 numerické atribúty v ktorých sa dajú hľadať odľahlé hodnoty. Najviac odľahlých hodnôt sme našli v atribúte **Stick Length** a v atribúte **Price** sme nenašli ani jeden.

Názov	Spodná hr.	Horná hr.	Počet od. hodnôt	Od. hodnoty
Price	-53.625	382.575	0	-
Flex	12.5	112.5	1	10
Stick Length	45	69	4	38, 42, 43, 44

Tabuľka 3: Odľahlé hodnoty

1.4 Analýza chýbajúcich hodnôt

V nasledujúcej tabuľke je zobrazený počet chýbajúcich hodnôt pre jednotlivé riadky. Atribúty **URL**, **Name**, **Price** a **Manufacturer** sa v tabuľke nenachádzajú, lebo nemajú ani jednu chýbajúcu hodnotu a rozhodol som sa ich do tabuľky nevložiť. Celkový počet chýbajúcich hodnôt v našom datasete bol 199 a najviac ich bolo v atribútoch **Hand** a **Stick Length**. Výrazne sa ešte vyskytli v atribúte **Blade Curve**. Počet riadkov s viac ako jednou chýbajúcou hodnotou bol 21.

Názov	Počet chýbajúcich hodnôt
Age Group	3
Hand	90
Flex	6
Stick Length	70
Blade Curve	18
Brand	2
Family	7
Composite Stick Brand	3
Celkový počet chýbajúcich hodnôt	199
Počet riadkov s viacerými chýbajúcimi hodnotami	21


Tabuľka 4: Chýbajúce hodnoty

1.5 Korelačná analýza

Keďže sme sa rozhodli, že náš dataset nemá žiadne ordinálne atribúty, tak korelačnú analýzu sme vyhodnotili len na tých numerických. Na vyhotovenie korelačnej analýzy sme využili internú metódu **Pandas Dataframe** s názvom `.corr()`, ktorej návratová hodnota je matica s korelačným indexom medzi jednotlivými atribútmi. Následne sme túto maticu vykreslili ako tepelnú mapu.

Hodnoty v matici sú symetrické a matica má jednotkovú diagonálu, ktorá znázorňuje koreláciu rovnakých atribútov. Vidíme že flex aj dĺžka hokejky celkom korelujú s cenou pravdepodobne kvôli tomu, že vyšší flex aj dĺžka hokejky korešpondujú s hokejkami pre dospelých hráčov, ktoré zvyknú byť drahšie. Najviac však koreluje flex práve s dĺžkou hokejky. Tieto hodnoty korelujú pravdepodobne kvôli tomu, že čím je hokejka dlhšia, tým sa ťažšie ohýba (má vyšší flex). Vysoký obrancovia mávajú

dlhé hokejky s vysokým flexom, aby mali tvrdé strely príklepom kedy čím je vyšší flex, tým rýchlejšie hokejka vystrelí s pukom po zahnutí hokejky hráčom.



Obr. 6: Korelačná matica numerických atribútov

2 Prvá varianta dátovej sady – Diskretizácia numerických atribútov

V tejto časti sme vykonali prieskum dátovej sady, konkrétne diskretizáciu numerických atribútov. Diskretizácia predstavuje dôležitý krok pri práci s dátami, ktorý umožňuje transformovať spojité hodnoty (napríklad reálne čísla, konkrétne napríklad atribút cena) na diskkrétne kategórie (napríklad celé čísla reprezentujúce intervaly). Tento postup sa využíva najmä pri algoritmoch, ktoré nepracujú dobre so spojitými číselnými hodnotami, alebo ak chceme zjednodušiť interpretáciu dát. Cieľom bolo podľa zadania vytvoriť novú verziu dátovej sady, ktorá je optimalizovaná pre ďalšie analýzy alebo algoritmy.

Úpravy dátovej sady

1. Dopĺňanie chýbajúcich hodnôt v atribúte Stick Length

- **Použitá metóda:** Chýbajúce hodnoty v atribúte `Stick Length` (dĺžka hokejky) boli nahradené priemernou dĺžkou hokejky v príslušnej vekovej skupine. Na tento účel sme použili metódu `apply` v kombinácii so slovníkom `mean_stick_length`, ktorý obsahoval priemerné hodnoty pre jednotlivé vekové skupiny. Po nahradení sme zabezpečili, že výsledné hodnoty budú celočíselné (`astype(int)`).

```
df['Stick Length'] = df.apply(lambda row: mean_stick_length[row['Age Group']]
                              if pd.isnull(row['Stick Length'])
                              else row['Stick Length'], axis=1)
df['Stick Length'] = df['Stick Length'].astype(int)
```

Takáto varianta dopĺňania chýbajúcich hodnôt na základe priemeru vekovej skupiny nám v tíme prišla ako logická voľba, pretože dĺžka hokejky môže byť závislá na fyzických charakteristikách, ktoré sa menia s vekom. Táto metóda minimalizuje šum spôsobený chýbajúcimi hodnotami a zachováva konzistenciu v rámci vekových skupín.

2. Dopĺňanie chýbajúcich hodnôt v atribúte Hand

- **Použitá metóda:** Chýbajúce hodnoty v atribúte `Hand` (strana, do ktorej je hokejka zahnutá) boli nahradené hodnotou `left`, `right`, čo znamená, že hokejka je vyrábaná pre obe ruky (strany). Na tento účel sme použili metódu `fillna`.

```
df['Hand'].fillna('left, right', inplace=True)
```

3. Odstraňovanie riadkov s viac ako dvomi chýbajúcimi hodnotami

- **Použitá metóda:** Riadky obsahujúce viac ako dve chýbajúce hodnoty boli odstránené pomocou podmienky na súčet NaN hodnôt v rámci jednotlivých riadkov.

```
df = df[df.isnull().sum(axis=1) <= 2]
```

- **Zdôvodnenie:** Riadky s viacerými chýbajúcimi hodnotami by mohli obsahovať príliš veľa neúplných informácií, ktoré by mohli skresľovať analýzy alebo modelovanie. Odstránením takýchto riadkov sme zvýšili kvalitu dátovej sady.

Poznámka: Týchto riadkov bolo 0, ale prišlo nám to ako vhodné obmedzenie pre budúcnosť

4. Odstraňovanie riadkov s chýbajúcimi hodnotami v kľúčových atribútoch

- **Použitá metóda:** Riadky, v ktorých chýbali hodnoty v atribútoch `Family` alebo `Blade Curve`, boli odstránené pomocou filtrovacích podmienok.

```
df = df[~df['Family'].isnull()]
df = df[~df['Blade Curve'].isnull()]
```

- **Zdôvodnenie:** Atribúty `Family` a `Blade Curve` predstavujú kľúčové informácie, ktoré sú dôležité pre analýzy. Ak tieto hodnoty chýbajú, nie je možné relevantne interpretovať príslušné riadky, a preto boli odstránené.

2.1 Kopírovanie dát:

Najprv sme vytvorili hlbokú kópiu pôvodnej dátovej sady pomocou metódy `__deepcopy__()`. Tento krok je nevyhnutný, aby sme zabezpečili, že originálne dáta zostanú nedotknuté. Hlboká kópia zabezpečuje, že všetky údaje a ich štruktúry sa kopírujú nezávisle, takže ak vykonáme zmeny na kópii, tieto zmeny neovplyvnia pôvodnú dátovú sadu. Takto sme mohli bez obáv experimentovať s dátami a zároveň si ponechať pôvodné hodnoty pre prípad porovnania v rámci vývoja alebo alternatívnych analýz. Kód na vytvorenie kópie vyzerá nasledovne:

```
df_first = df.__deepcopy__()
```

2.2 Diskretizácia numerických atribútov:

Na prevod spojitých hodnôt do diskrétnych kategórií sme použili funkciu `pandas.qcut`. Táto funkcia umožňuje rozdeliť hodnoty do rovnakých kvantíl, teda do intervalov, ktoré obsahujú približne rovnaký počet dátových bodov. Výhodou takéhoto prístupu je, že sa eliminujú extrémne hodnoty a zjednodušuje sa analýza. Nasledujú konkrétne atribúty, ktoré boli diskretizované:

- **Atribút Price:** Tento atribút predstavuje cenu, ktorá môže obsahovať široký rozsah hodnôt. Aby sme zjednodušili analýzu, rozdelili sme hodnoty do 20 intervalov (kvantíl), pričom každému intervalu sme priradili diskrétnu hodnotu (0 až 19). Každý interval teda reprezentuje určitú úroveň ceny. Diskretizácia bola vykonaná nasledovne:

```
df_first['Price'] = pd.qcut(df_first['Price'], q=20, labels=False)
```

- **Atribút Flex:** Tento atribút vyjadruje flexibilitu a má taktiež spojité hodnoty. Pre lepšiu interpretáciu sme tieto hodnoty rozdelili do 7 intervalov (kvantíl), čím sme získali 7 diskrétnych kategórií reprezentujúcich úrovne flexibility. Diskretizácia prebiehala podľa nasledujúceho kódu:

```
df_first['Flex'] = pd.qcut(df_first['Flex'], q=7, labels=False)
```

- **Atribút Stick Length:** Dĺžka hokejky, ktorá je reprezentovaná spojitými číselnými hodnotami, bola rozdelená do 5 intervalov. Toto rozdelenie zabezpečilo prehľadnejšie kategórie dĺžok, ktoré je možné lepšie analyzovať alebo použiť v modelovaní. Použili sme nasledovný kód:

```
df_first['Stick Length'] = pd.qcut(df_first['Stick Length'], q=5, labels=False)
```

2.3 Uloženie spracovaných dát:

Po úspešnej diskretizácii sme výslednú verziu dátovej sady uložili do súboru vo formáte CSV (comma-separated values) pod názvom `data_preprocessed_first.csv`. Použitý kód bol:

```
df_first.to_csv('data_preprocessed_first.csv', index=False)
```

Postup diskretizácie môže byť užitočný napríklad pri rozhodovacích stromoch alebo clustrovaní.

3 Druhá varianta dátovej sady – Normalizácia numerických atribútov a transformácia kategorických atribútov na numerické

V tejto variante dátovej sady sme vykonali dve hlavné úpravy: normalizáciu numerických atribútov a transformáciu kategorických atribútov na numerické hodnoty. Tieto kroky sú dôležité na prípravu dát pre algoritmy, ktoré vyžadujú numerické vstupy a citlivo reagujú na rozdiely v rozsahoch hodnôt.

3.1 Kopírovanie dát:

Na začiatku sme vytvorili hlbokú kópiu pôvodnej dátovej sady pomocou metódy `--deepcopy--()`. Tento krok zabezpečil, že pôvodné dáta zostanú nezmenené, pričom upravená verzia dát je izolovaná pre experimenty a vývoj.

3.2 Normalizácia numerických atribútov:

Pre numerické atribúty sme vykonali normalizáciu, aby hodnoty ležali v intervale od 0 do 1. Použitý vzorec na normalizáciu je:

$$normalized_value = \frac{value - min}{max - min}$$

Táto metóda (Min-max normalizácia) eliminuje rozdiely v rozsahoch hodnôt a zlepšuje porovnateľnosť medzi atribútmi. Normalizované boli nasledujúce atribúty: `Price`, `Flex` a `Stick Length`. Implementácia prebiehala nasledovne:

```
attributes = ['Price', 'Flex', 'Stick Length']
for attribute in attributes:
    df_second[attribute] = (df[attribute] - df[attribute].min()) /
                           (df[attribute].max() - df[attribute].min())
```

Alternatívne metódy:

- *Štandardizácia (z-score normalizácia)*: Transformuje hodnoty tak, aby mali strednú hodnotu 0 a smerodajnú odchýlku 1. Táto metóda by bola vhodná, ak by bolo potrebné odstrániť vplyv extrémnych hodnôt a zachovať normálne rozdelenie.
- *Robust scaling*: Používa medián a interkvartilové rozpätie na škálovanie, čo je vhodné pre údaje s výskytom odľahlých hodnôt, čo ale nebol prípad v našich dátach.

3.3 Transformácia kategorických atribútov na numerické:

Kategorické atribúty boli transformované na numerické hodnoty pomocou metódy `astype('category').cat.codes`. Táto transformácia priradzuje každej kategórii jedinečný číselný kód (napríklad 0, 1, 2, ...). Tento postup je nevyhnutný pri práci s algoritmami, ktoré vyžadujú číselné vstupy. Nasledujúce kategorické atribúty boli transformované:

- `Manufacturer`
- `Age Group`
- `Hand`
- `Blade Curve`
- `Brand`

- Family
- Composite Stick Brand

Alternatívne metódy:

- *One-hot encoding*: Pre každú kategóriu sa vytvorí samostatný binárny atribút.
- *Ordinal encoding*: Kategóriám sa priraduje číslo podľa ich poradia. Táto metóda sa využíva, ak má kategória prirodzené poradie (napr. malý, stredný, veľký). V našej dátovej sade sme takýto atribút nemali.

3.4 Uloženie spracovaných dát:

Upravenú dátovú sadu sme uložili do súboru vo formáte CSV pod názvom `data_preprocessed_second.csv`.

```
df_second.to_csv('data_preprocessed_second.csv', index=False)
```

Dôvody úprav a navrhnuté dolovacie úlohy

- **Normalizácia**: Normalizácia je nevyhnutná pri práci s algoritmami, ktoré sú citlivé na rozdiely v rozsahoch hodnôt (napríklad KNN, SVM alebo gradientný zostup). Týmto spôsobom sa eliminuje riziko, že atribúty s veľkými hodnotami dominujú nad ostatnými.
- **Transformácia kategórií**: Transformácia kategorických hodnôt na číselné umožňuje ich použitie vo výpočtoch. Táto metóda je jednoduchá, avšak stráca prípadné poradie medzi kategóriami, ak také existuje. Ak by poradie bolo dôležité, bolo by vhodné zvážiť iné metódy, napríklad one-hot encoding, túto variantu sme v tíme diskutovali nad atribútom Age Group, ktorý sme nakoniec zaradili za nie ordinálny.

Navrhnuté dolovacie úlohy

Na základe spracovaných variánt dátovej sady navrhujeme nasledujúce konkrétne úlohy pre dolovanie znalostí s naznačením rodiny dolovacieho algoritmu:

1. **Predikcia preferovanej hokejky podľa veku a ďalších atribútov:** Cieľom tejto úlohy je vytvoriť model, ktorý na základe veku, dĺžky hokejky a ďalších charakteristík predpovedá, aká hokejka (vlastnosti ako **Family**, **Blade Curve**, či **Flex**) by bola najvhodnejšia pre daného hráča. Táto úloha by mohla využiť klasifikačné algoritmy (napr. Random Forest alebo SVM).
2. **Klasifikácia podľa preferencie ruky:** Táto úloha zahŕňa identifikáciu, či hráč preferuje ľavú alebo pravú ruku, na základe ostatných atribútov (napr. dĺžka hokejky, veková skupina alebo **Blade Curve**). Úloha môže byť realizovaná binárnou klasifikáciou.
3. **Analýza segmentácie hráčov:** Pomocou clustrovacích algoritmov (napr. K-Means alebo DB-SCAN) by bolo možné identifikovať segmenty hráčov s podobnými preferenciami hokejok. Výsledky by mohli byť využité na prispôsobenie marketingových stratégií alebo návrh nových produktov.
4. **Detekcia anomálií:** Úlohou je identifikovať hráčov, ktorých výber hokejky nezodpovedá bežným vzorcom. Táto úloha by mohla byť realizovaná pomocou metód ako Isolation Forest alebo LOF (Local Outlier Factor).
5. **Analýza trendov vo vlastnostiach hokejok:** Cieľom tejto úlohy je identifikovať trendy v atribútoch hokejok (napr. flexibilita, dĺžka, tvar čepele) v závislosti od veku hráčov alebo iných charakteristík. Táto analýza by mohla odhaliť, aké vlastnosti sú v jednotlivých vekových skupinách preferované.